

# Laboratorio 6 - Asociación, tablas, loops y limpieza de datos

## Métodos Cuantitativos

Carlos Eduardo Molina Berumen

El Colegio de México

14 de noviembre de 2025



# Repaso

Ya sabemos como:

- Hacer una regresión lineal
- Gráficar una regresión lineal
- Buscar la covarianza de dos variables.

# En este lab aprenderemos:

- Más medidas de asociación
- Cómo hacer tablas de contingencia
- Cómo hacer loops
- Cómo limpiar bases de datos

# Explicación conceptual

**Covarianza:** cómo dos variables numéricas varían juntas. No estandarizada.

**Coefficiente de determinación  $R^2$ :** qué proporción de la variación de la VD es explicada por la VI. Nos la da la regresión lineal.

**Coefficiente de correlación de Pearson:** es una versión estandarizada de la covarianza que va de -1 a 1.

**Chi cuadrada  $\chi^2$ :** se usa para ver si dos variables categóricas están relacionadas o son independientes.

Coefficiente de Pearson:

```
library(palmerpenguins)
library(stargazer)
penguins <- na.omit(penguins)
```

```
cor.test(penguins$bill_length_mm, penguins$body_mass_g,  
         method = "pearson")
```

Pearson's product-moment correlation

```
data:  penguins$bill_length_mm and penguins$body_mass_g  
t = 13.276, df = 331, p-value < 2.2e-16  
alternative hypothesis: true correlation is not equal to 0  
95 percent confidence interval:  
 0.5145745 0.6554058  
sample estimates:  
      cor  
0.5894511
```

Hay una relación positiva moderada-fuerte y estadísticamente significativa.

También se puede usar `cor()`, pero `cor.test()` les da una relación más completa.

# Chi cuadrada $\chi^2$

**Recordatorio:** La chi cuadrada  $\chi^2$  mide la relación entre dos variables categóricas. No numéricas.

Primer paso, hacer una tabla de contingencia.

## Tabla de contingencia

Tabla en forma de matriz que organiza dos o más variables categóricas. Ella mide la **frecuencia** de la combinación de los cruces entre cada categoría.

```
tabla <- table(penguins$species, penguins$island)
tabla
```

	Biscoe	Dream	Torgersen
Adelie	44	55	47
Chinstrap	0	68	0

```
objeto <- chisq.test(tabla)

stargazer(objeto, type = "text")
```

% Error: Unrecognized object type.

Hay relación estadísticamente significativa entre las variables.

## Parte dos: loops

Los loops son una herramienta muy útil para evitar tareas repetitivas en r. En lugar de pedirle a r que imprima el cuadrado de cada entero del uno al cinco por separado, lo podemos hacer en un solo comando.

```
for (i in 1:5) {  
  print(i**2)  
}
```

```
[1] 1  
[1] 4  
[1] 9  
[1] 16  
[1] 25
```



Hagámos un loop más interesante:

```
library(fivethirtyeight)
data <- airline_safety

for (i in 1:nrow(data)) {
  aerolinea <- data$airline[i]
  fatalidades <- data$fatalities_00_14[i]

  if (fatalidades > 0) {
    cat("La aerolínea", aerolinea, "tuvo", fatalidades,
        "fatalidades entre el 2000 y el 2014.\n")
  }
}
```

La aerolínea Aeroflot tuvo 88 fatalidades entre el 2000 y el 2014.

La aerolínea Air France tuvo 337 fatalidades entre el 2000 y el 2014.

La aerolínea Air India tuvo 158 fatalidades entre el 2000 y el 2014.

La aerolínea Air New Zealand tuvo 7 fatalidades entre el 2000 y el 2014.

## Parte 3: limpiar datos.

```
library(ggplot2)  
economics <- economics
```

# Seleccionar columnas

```
library(dplyr)
unemployment <- select(economics, date, unemploy, psavert)
head(unemployment, n= 2)
```

```
# A tibble: 2 x 3
  date          unemploy psavert
  <date>        <dbl>    <dbl>
1 1967-07-01      2944      12.6
2 1967-08-01      2945      12.6
```

```
df1 <- select(economics, date:pop)
head(df1, n = 2)
```

```
# A tibble: 2 x 3
  date      pce    pop
<date>    <dbl> <dbl>
1 1967-07-01  507. 198712
2 1967-08-01  510. 198911
```

```
df2 <- select(economics, starts_with("p"))
head(df2, n = 2)
```

```
# A tibble: 2 x 3
  pce    pop psavert
<dbl> <dbl> <dbl>
1  507. 198712    12.6
2  510. 198911    12.6
```

# Quitar columnas

```
df3 <- select(economics, -c(pop, uempmed))  
head(df3)
```

```
# A tibble: 6 x 4  
  date          pce psavert unemploy  
  <date>      <dbl>   <dbl>   <dbl>  
1 1967-07-01  507.    12.6    2944  
2 1967-08-01  510.    12.6    2945  
3 1967-09-01  516.    11.9    2958  
4 1967-10-01  512.    12.9    3143  
5 1967-11-01  517.    12.8    3066  
6 1967-12-01  525.    11.8    3018
```

## Pivot longer (table ancha a tabla larga)

Sirve para crear una nueva variable “indicator” que contenga los datos de personal consumption expenditures, personal savings rate y number of unemployed in thousands.

```
#install.packages("tidyr")  
library(tidyr)  
  
df4<- pivot_longer(  
  economics,  
  cols = c(pce, psavert, unemploy),  
  names_to = "indicator", values_to = "value")
```

```
head(df4)
```

```
# A tibble: 6 x 5
```

	date	pop	uempmed	indicator	value
	<date>	<dbl>	<dbl>	<chr>	<dbl>
1	1967-07-01	198712	4.5	pce	507.
2	1967-07-01	198712	4.5	psavert	12.6
3	1967-07-01	198712	4.5	unemploy	2944
4	1967-08-01	198911	4.7	pce	510.
5	1967-08-01	198911	4.7	psavert	12.6
6	1967-08-01	198911	4.7	unemploy	2945

## Pivot wider (tabla larga a tabla ancha)

Proceso inverso a pivot longer. Sirve para que ahora nuestra columna “indicator” y “values” se conviertan en columnas “pce”, “psavert”, “unemploy”.

```
df5 <- pivot_wider(  
  df4,  
  names_from = indicator,  
  values_from = value  
)
```



```
head(df5)
```

```
# A tibble: 6 x 6
```

	date	pop	uempmed	pce	psavert	unemploy
	<date>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>
1	1967-07-01	198712	4.5	507.	12.6	2944
2	1967-08-01	198911	4.7	510.	12.6	2945
3	1967-09-01	199113	4.6	516.	11.9	2958
4	1967-10-01	199311	4.9	512.	12.9	3143
5	1967-11-01	199498	4.7	517.	12.8	3066
6	1967-12-01	199657	4.8	525.	11.8	3018

# En suma

- **Extraer columnas:** `select(col1, col2)`
- **Quitar columnas:** `select(-col)`
- **De ancho a largo:** `pivot_longer()`
- **De largo a ancho:** `pivot_wider()`

Muchas gracias a todas!!! :)))

eduardo.molina@alumnos.cide.edu

carlos.e.molinaberumen@outlook.com